

Exercice 1 : Dyspnée

Énoncé

Sur la base des données présentées dans le tableau, construire un arbre de décision permettant de savoir dans quel ordre effectuer les tests. Les quatre premières variables sont les variables d'entrée (X), la cinquième est la variable cible (Y).

Données

Age	Fumeur	Asthmatique	Poids	Dyspnée
Jeune	Oui	Non	Normal	Non
Jeune	Oui	Oui	Maigre	Non
Adulte	Non	Non	Corpulent	Non
Âgé	Oui	Non	Maigre	Non
Âgé	Non	Non	Normal	Non
Adulte	Oui	Oui	Corpulent	Oui
Jeune	Non	Non	Normal	Non
Adulte	Oui	Non	Normal	Oui
Adulte	Non	Oui	Maigre	Non
Âgé	Oui	Non	Corpulent	Oui
Âgé	Oui	Oui	Normal	Oui
Âgé	Oui	Non	Corpulent	Oui
Âgé	Non	Oui	Normal	Non
Jeune	Non	Non	Normal	Non

Total : 14 exemples

- **Dyspnée = Oui : 5**
- **Dyspnée = Non : 9**

1. Calculer l'entropie de la variable cible (Dyspnée)

L'entropie mesure l'impureté de la variable cible.

Formule : $H(Y) = -\sum_i p_i \log_2(p_i)$

Avec :

- $p(\text{Oui}) = \frac{5}{14}$
- $p(\text{Non}) = \frac{9}{14}$

$$H(\text{Dyspnée}) = -\frac{5}{14} \log_2 \left(\frac{5}{14} \right) - \frac{9}{14} \log_2 \left(\frac{9}{14} \right)$$

$$H(\text{Dyspnée}) = -\frac{5}{14} \times (-1.485) - \frac{9}{14} \times (-0.637)$$

$$H(\text{Dyspnée}) = 0.530 + 0.410 = \boxed{0.940 \text{ bits}}$$

2. Calculer l'entropie des 4 variables X et déduire celle à choisir en premier

Pour chaque variable, on calcule le **gain d'information** : $\text{Gain}(Y, X) = H(Y) - H(Y|X)$

où $H(Y|X)$ est l'entropie conditionnelle : $H(Y|X) = \sum_{v \in \text{valeurs}(X)} \frac{|X=v|}{|D|} \times H(Y|X=v)$

2.1. Variable **Age**

Age	Total	Oui	Non	Entropie
Jeune	4	0	4	0
Adulte	4	2	2	1.000
Âgé	6	3	3	1.000

$$H(\text{Dyspnée}|\text{Age}) = \frac{4}{14}(0) + \frac{4}{14}(1.000) + \frac{6}{14}(1.000) = 0 + 0.286 + 0.429 = 0.715$$

$$\text{Gain}(\text{Age}) = 0.940 - 0.715 = \boxed{0.225}$$

2.2. Variable **Fumeur**

Fumeur	Total	Oui	Non	Entropie
Oui	8	5	3	0.954
Non	6	0	6	0

$$H(\text{Dyspnée}|\text{Fumeur}) = \frac{8}{14}(0.954) + \frac{6}{14}(0) = 0.545 + 0 = 0.545$$

$$\text{Gain}(\text{Fumeur}) = 0.940 - 0.545 = \boxed{0.395}$$

2.3. Variable **Asthmatique**

Asthmatique	Total	Oui	Non	Entropie
Oui	4	2	2	1.000
Non	10	3	7	0.881

$$H(\text{Dyspnée}|\text{Asthmatique}) = \frac{4}{14}(1.000) + \frac{10}{14}(0.881) = 0.286 + 0.629 = 0.915$$

$$G(\text{Gain}(\text{Asthmatique})) = 0.940 - 0.915 = \boxed{0.025}$$

2.4. Variable **Poids**

Poids	Total	Oui	Non	Entropie
Normal	6	2	4	0.918
Maigre	3	0	3	0
Corpulent	5	3	2	0.971

$$H(\text{Dyspnée}|\text{Poids}) = \frac{6}{14}(0.918) + \frac{3}{14}(0) + \frac{5}{14}(0.971) = 0.393 + 0 + 0.347 = 0.740$$

$$G(\text{Gain}(\text{Poids})) = 0.940 - 0.740 = \boxed{0.200}$$

Récapitulatif des gains d'information :

Variable	Gain d'information
Fumeur	0.395
Age	0.225
Poids	0.200
Asthmatique	0.025

→ **La variable à choisir en premier est : Fumeur** (gain maximal)

3. Effectuer la même démarche sur les différentes branches non terminales

Branche : **Fumeur = Non**

6 exemples, tous avec Dyspnée = Non → **Nœud terminal : Non**

Branche : **Fumeur = Oui**

8 exemples : 5 Oui, 3 Non

$$H(\text{Dyspnée}|\text{Fumeur=Oui}) = 0.954$$

On calcule le gain pour les variables restantes :

3.1. Variable Age (Fumeur = Oui)

Age	Total	Oui	Non	Entropie
-----	-------	-----	-----	----------

Age	Total	Oui	Non	Entropie
Jeune	2	0	2	0
Adulte	2	2	0	0
Âgé	4	3	1	0.811

$$H(\text{Dyspnée}|\text{Age, Fumeur=Oui}) = \frac{2}{8}(0) + \frac{2}{8}(0) + \frac{4}{8}(0.811) = 0.406$$

$$G(\text{Age}) = 0.954 - 0.406 = \boxed{0.548}$$

3.2. Variable Asthmatique (Fumeur = Oui)

Asthmatique	Total	Oui	Non	Entropie
Oui	3	2	1	0.918
Non	5	3	2	0.971

$$H(\text{Dyspnée}|\text{Asthmatique, Fumeur=Oui}) = \frac{3}{8}(0.918) + \frac{5}{8}(0.971) = 0.951$$

$$G(\text{Asthmatique}) = 0.954 - 0.951 = \boxed{0.003}$$

3.3. Variable Poids (Fumeur = Oui)

Poids	Total	Oui	Non	Entropie
Normal	2	2	0	0
Maigre	2	0	2	0
Corpulent	4	3	1	0.811

$$H(\text{Dyspnée}|\text{Poids, Fumeur=Oui}) = \frac{2}{8}(0) + \frac{2}{8}(0) + \frac{4}{8}(0.811) = 0.406$$

$$G(\text{Poids}) = 0.954 - 0.406 = \boxed{0.548}$$

→ Les variables Age et Poids ont le même gain (0.548). On choisit : Age

Sous-branches de Age (quand Fumeur = Oui) :

- Age = Jeune : 2 exemples, tous Non → Nœud terminal : Non
- Age = Adulte : 2 exemples, tous Oui → Nœud terminal : Oui
- Age = Âgé : 4 exemples (3 Oui, 1 Non) → Continuer la division

Pour Age = Âgé et Fumeur = Oui (4 exemples : 3 Oui, 1 Non)

Variables restantes : Asthmatique, Poids

Asthmatique :

- Oui : 2 exemples (1 Oui, 1 Non) → Entropie = 1.000

- Non : 2 exemples (2 Oui, 0 Non) → Entropie = 0

$$H(\text{Dyspnée}|\text{Asthmatique}) = \frac{2}{4}(1.000) + \frac{2}{4}(0) = 0.500$$

$$\text{Gain}(\text{Asthmatique}) = 0.811 - 0.500 = 0.311$$

Poids :

- Normal : 1 exemple (Oui) → Entropie = 0
- Corpulent : 3 exemples (2 Oui, 1 Non) → Entropie = 0.918


$$H(\text{Dyspnée}|\text{Poids}) = \frac{1}{4}(0) + \frac{3}{4}(0.918) = 0.689$$

$$\text{Gain}(\text{Poids}) = 0.811 - 0.689 = 0.122$$

→ On choisit **Asthmatique (gain = 0.311)**

- **Asthmatique = Oui** : continuer (1 Oui, 1 Non) → besoin de Poids
 - Poids = Normal : 1 exemple (Oui) → **Oui**
 - Poids = Corpulent : 1 exemple (Non) → **Non**
- **Asthmatique = Non** : 2 exemples, tous Oui → **Nœud terminal : Oui**

4. Arbre de décision obtenu



Règles de décision :

1. Si **Fumeur = Non** → **Dyspnée = Non**
2. Si **Fumeur = Oui et Age = Jeune** → **Dyspnée = Non**
3. Si **Fumeur = Oui et Age = Adulte** → **Dyspnée = Oui**
4. Si **Fumeur = Oui et Age = Âgé et Asthmatique = Non** → **Dyspnée = Oui**
5. Si **Fumeur = Oui et Age = Âgé et Asthmatique = Oui et Poids = Normal** → **Dyspnée = Oui**
6. Si **Fumeur = Oui et Age = Âgé et Asthmatique = Oui et Poids = Corpulent** → **Dyspnée = Non**

Conclusion

L'arbre de décision permet de classer la dyspnée en fonction des 4 variables d'entrée. L'ordre des tests à effectuer est :

1. **Fumeur** (meilleur gain d'information)
2. **Age** (pour la branche Fumeur = Oui)
3. **Asthmatique** (pour la branche Age = Âgé)
4. **Poids** (pour affiner certains cas)